

Documentazione dei dataset

Origine dei dati

I dataset utilizzati nel progetto provengono dalla Paleobiology Database, una banca dati pubblica dedicata alla raccolta di informazioni paleontologiche. La piattaforma raccoglie dati relativi a fossili, taxa, località di ritrovamento, intervalli geologici, coordinate geografiche, classificazioni tassonomiche e riferimenti bibliografici.

I dati sono stati ottenuti tramite API pubblica della Paleobiology Database, utilizzando l'endpoint dedicato alle fossil occurrences, cioè ai record di presenza/ritrovamento fossile. Ogni record rappresenta una segnalazione fossile collegata a una determinata collezione, località, taxon e riferimento scientifico.

I file utilizzati nel progetto sono:

- `dinos.csv`
- `plants.csv`

Entrambi i dataset sono stati scaricati in formato CSV e successivamente rinominati per renderli più semplici da gestire nel progetto.

Dataset 1: `dinos.csv`

Descrizione generale

Il dataset `dinos.csv` contiene record fossili associati al gruppo tassonomico Dinosauria. La query originale è stata costruita usando il parametro `base_name=Dinosauria`, che restituisce le occorrenze collegate a Dinosauria e ai taxa discendenti.

Il dataset contiene 37.790 record e 38 attributi.

È importante notare che, dal punto di vista tassonomico, il gruppo Dinosauria può includere anche gli uccelli, perché gli uccelli sono considerati discendenti dei dinosauri teropodi. Per questo motivo, nel dataset compaiono anche record classificati come Aves. Se l'obiettivo dell'analisi è concentrarsi sui dinosauri mesozoici "classici", sarà utile applicare un filtro durante la fase di trasformazione, ad esempio escludendo Aves oppure limitando l'analisi agli intervalli Triassic, Jurassic e Cretaceous.

Contenuto del dataset

Il dataset contiene informazioni relative a:

- identificativo dell'occorrenza fossile;
- nome identificato nel record originale;
- nome accettato secondo la classificazione PBDB;
- rango tassonomico;
- intervallo geologico;
- età minima e massima in milioni di anni;
- coordinate geografiche attuali;
- paese, stato e contea;
- precisione delle coordinate;
- formazione geologica;
- gruppo geologico;
- classificazione tassonomica: phylum, class, order, family, genus;
- riferimento bibliografico associato al record.

Attributi principali

Gli attributi più utili per l'analisi sono:

- **occurrence_no**: identificativo univoco dell'occorrenza fossile;
- **collection_no**: identificativo della collezione/località;
- **identified_name**: nome con cui il fossile è stato identificato nel record originale;
- **accepted_name**: nome tassonomico accettato;
- **accepted_rank**: rango tassonomico del nome accettato;
- **early_interval**: intervallo geologico iniziale;
- **late_interval**: eventuale intervallo geologico finale;
- **max_ma**: età massima stimata, in milioni di anni;
- **min_ma**: età minima stimata, in milioni di anni;
- **lng**: longitudine;
- **lat**: latitudine;
- **cc**: codice paese;
- **state**: stato o regione;
- **county**: contea o area locale;
- **formation**: formazione geologica;
- **geological_group**: gruppo geologico;
- **phylum, class, order, family, genus**: classificazione tassonomica.

Possibili utilizzi

Il dataset può essere utilizzato per analizzare:

- distribuzione geografica dei ritrovamenti fossili di dinosauri;
- distribuzione dei fossili per periodo geologico;
- paesi con il maggior numero di ritrovamenti;
- taxa più rappresentati;
- confronto tra gruppi tassonomici;
- relazione tra ritrovamenti fossili e formazioni geologiche;

- evoluzione della presenza fossile nel tempo geologico.
-

Dataset 2: plants.csv

Descrizione generale

Il dataset `plants.csv` contiene record fossili associati al gruppo tassonomico Plantae, filtrati sugli intervalli geologici Triassic, Jurassic e Cretaceous. Questi tre intervalli compongono il Mesozoico, cioè l'era geologica in cui vissero e si diffusero i dinosauri non-aviani.

Il dataset contiene 57.394 record e 38 attributi.

La scelta di questo dataset è collegata al tema del progetto perché le piante fossili permettono di analizzare il contesto ambientale ed ecologico in cui vivevano i dinosauri, soprattutto in relazione agli ecosistemi terrestri e alla presenza di vegetazione.

Contenuto del dataset

Il dataset contiene informazioni relative a:

- identificativo dell'occorrenza fossile vegetale;
- nome identificato nel record originale;
- nome accettato secondo la classificazione PBDB;
- rango tassonomico;
- intervallo geologico;
- età minima e massima in milioni di anni;
- coordinate geografiche;
- paese, stato e contea;
- precisione delle coordinate;
- formazione geologica;
- classificazione tassonomica: phylum, class, order, family, genus;
- riferimento bibliografico associato al record.

Attributi principali

Gli attributi più utili per l'analisi sono:

- `occurrence_no`: identificativo univoco dell'occorrenza fossile;
- `collection_no`: identificativo della collezione/località;
- `identified_name`: nome originale indicato nel record;
- `accepted_name`: nome tassonomico accettato;
- `accepted_rank`: rango tassonomico del nome accettato;
- `early_interval`: intervallo geologico principale;
- `late_interval`: eventuale intervallo geologico finale;

- **max_ma**: età massima stimata, in milioni di anni;
- **min_ma**: età minima stimata, in milioni di anni;
- **lng**: longitudine;
- **lat**: latitudine;
- **cc**: codice paese;
- **state**: stato o regione;
- **county**: contea o area locale;
- **formation**: formazione geologica;
- **geological_group**: gruppo geologico;
- **phylum, class, order, family, genus**: classificazione tassonomica.

Possibili utilizzi

Il dataset può essere utilizzato per analizzare:

- distribuzione geografica delle piante fossili nel Mesozoico;
 - periodi geologici con maggiore presenza di fossili vegetali;
 - paesi e regioni con più ritrovamenti vegetali;
 - famiglie o generi vegetali più frequenti;
 - confronto tra presenza di vegetazione fossile e presenza di dinosauri;
 - studio degli ecosistemi mesozoici attraverso dati paleontologici.
-

Collegamento tra i due dataset

I due dataset possono essere utilizzati insieme perché provengono dalla stessa fonte, hanno una struttura simile e condividono molte colonne.

Il collegamento non avviene tramite una chiave unica diretta come in un database relazionale classico, ma tramite attributi comuni utili all'analisi:

- periodo geologico;
- età in milioni di anni;
- coordinate geografiche;
- paese;
- formazione geologica;
- collezione o località;
- classificazione tassonomica.

L'obiettivo non è dimostrare una relazione causale diretta tra un singolo fossile di dinosauro e una singola pianta fossile, ma analizzare la possibile sovrapposizione geografica e temporale tra ritrovamenti di dinosauri e ritrovamenti vegetali. In questo modo è possibile costruire una lettura più ampia degli ecosistemi mesozoici.

Motivazione della scelta

La scelta dei dataset è motivata dal fatto che dinosauri e piante fossili appartengono allo stesso contesto paleontologico e possono essere analizzati insieme per ricostruire, almeno in modo esplorativo, alcuni aspetti degli ecosistemi del Mesozoico.

Il dataset dei dinosauri permette di studiare la distribuzione dei ritrovamenti fossili legati a Dinosauria, mentre il dataset delle piante permette di analizzare la presenza di vegetazione fossile negli stessi grandi intervalli temporali. L'unione dei due dataset consente quindi di costruire una dashboard non solo descrittiva, ma anche interpretativa, basata su spazio, tempo geologico e categorie tassonomiche.

Questa scelta è coerente con un progetto di Data Management perché richiede acquisizione dati da sorgente esterna, pulizia, trasformazione, caricamento in database e visualizzazione tramite dashboard interattiva.

Possibili analisi per la dashboard

La dashboard potrà includere analisi come:

- numero totale di occorrenze fossili per dataset;
- distribuzione dei fossili per periodo geologico;
- distribuzione geografica dei ritrovamenti su mappa;
- confronto tra numero di fossili di dinosauri e fossili vegetali per paese;
- confronto tra fossili di dinosauri e piante per intervallo geologico;
- top 10 paesi con più ritrovamenti;
- top 10 generi o famiglie più frequenti;
- analisi della presenza di coordinate mancanti;
- filtri per periodo, paese, classe tassonomica e formazione geologica.

Possibili KPI:

- totale record dinosauri;
 - totale record piante fossili;
 - numero di paesi rappresentati;
 - percentuale di record con coordinate disponibili;
 - intervallo geologico con più ritrovamenti;
 - paese con più occorrenze fossili.
-

Qualità dei dati e possibili trasformazioni

Durante la fase di preprocessing sarà necessario controllare:

- valori mancanti;
- duplicati;
- coordinate mancanti o non precise;
- taxa non specificati;
- campi geologici incompleti;
- presenza di record non coerenti con l'obiettivo dell'analisi.

Possibili trasformazioni:

1. Rimozione o gestione dei valori nulli nelle colonne più importanti.
2. Eliminazione di eventuali duplicati.
3. Creazione di una colonna `dataset_type` con valori `Dinosauria` e `Plantae`.
4. Creazione di una colonna `mid_ma`, calcolata come media tra `max_ma` e `min_ma`.
5. Creazione di una colonna `period_group` per raggruppare Triassico, Giurassico e Cretaceo.
6. Normalizzazione dei nomi dei paesi e delle categorie tassonomiche.
7. Filtro dei record con coordinate valide per le visualizzazioni geografiche.
8. Eventuale esclusione della classe `Aves` dal dataset dinosauri, se si vuole limitare l'analisi ai dinosauri non-aviani.

Limiti del dataset

I dati della Paleobiology Database derivano da pubblicazioni scientifiche e contributi inseriti nel tempo. Per questo motivo il dataset non rappresenta necessariamente tutti i fossili esistenti, ma solo quelli registrati e disponibili nella banca dati.

Inoltre, la distribuzione dei fossili può essere influenzata da fattori esterni, come:

- maggiore attività di ricerca in alcuni paesi;
- diversa accessibilità dei siti fossiliferi;
- diversa conservazione dei fossili nelle rocce;
- differenze nella qualità delle informazioni inserite;
- presenza di record con coordinate approssimative o mancanti;
- aggiornamenti continui del database.

Per questi motivi, le analisi devono essere interpretate come esplorative e descrittive, evitando conclusioni causali troppo forti.

Citazione della sorgente

I dati sono stati ottenuti dalla Paleobiology Database tramite API pubblica.

Sorgente dati: Paleobiology Database

Tipo di dati: fossil occurrences

Formato: CSV

Data di consultazione/download: 18/06/2026

File utilizzati: `dinos.csv` e `plants.csv`

Per garantire la replicabilità del progetto, nel documento tecnico è opportuno indicare anche i parametri utilizzati per scaricare i dati:

- dinosauri: `base_name=Dinosauria,`
`show=coords,attr,loc,time,strat,phylo`
- piante fossili: `base_name=Plantae,`
`interval=Triassic,Jurassic,Cretaceous,`
`show=coords,attr,loc,time,strat,phylo`